

Höhere Algorithmik

Mitschrift

Max Wisniewski

WS 2011/2012
24. Oktober 2011

Inhaltsverzeichnis

1	Einleitung	2
1.1	Ziel	2
1.2	Algorithmus	2
2	Repräsentant einer Menge	3
2.1	Naiver Ansatz	3
2.2	K - SELECT	3
2.2.1	Das Problem	4
2.2.2	Algorithmus I in $\Theta(n \cdot \log n)$	4
2.2.3	SELECT in $O(n)$	4
2.2.4	Implementierung von SPLITTER	5

Kapitel 1

Einleitung

1.1 Ziel

Bisher haben wir einfache solcher Algorithmen betrachtet (ALP1, ALP3, etc.). In dieser Vorlesung werden wir uns nun mit komplexeren Problemen beschäftigen. Wir wollen die Probleme unter folgenden Aspekten betrachten:

- Entwurf von Algorithmen
- Analyse dieser Algorithmen
- Bewertung dieser Algorithmen

1.2 Algorithmus

Def.: Ein Algorithmus ist ein endlich beschriebenes, effektives Verfahren, das eine Eingabe in eine Ausgabe überführt.

Zu Beginn betrachten wir ein einfaches Problem.

Kapitel 2

Repräsentant einer Menge

Gegeben sei folgendes statistisches Problem:

Es seien n Zahlen / Datensätze gegeben, wobei $n \gg 0$ gilt.

Gesucht ist ein Repräsentativer Wert für diese Menge.

2.1 Naiver Ansatz

Idee Wir verwenden den Durchschnitt / Mittelwert.

Die Laufzeit ist einfach, da wir nur einmal über alle Datensätze müssen. Setzen wir dabei eine konstante Zeit für Addition und Division voraus, ist die Laufzeit $O(n)$.

Problem: Der Mittelwert ist Anfällig für Außreißer und daher nicht sehr aussagekräftig.

Sind beispielsweise $n - 1$ Werte zwischen 0 und 10 und ein n ter liegt bei 10.000.000 so wird das ganze Ergebnis zu diesem Wert hin verfälscht.

Dieser Repräsentant ist leicht zu berechnen, aber nicht sehr schön.
Betrachten wir daher einen anderen Ansatz.

2.2 K - SELECT

Def.: Ein Element s einer total geordneten Menge S hat den Rang k
: \Leftrightarrow es gibt genau $(k - 1)$ Elemente in S , die kleiner sind als s .

Man schreibt dafür $rg(s)$.

Def.: Sei S total geordnet mit $n = |S|$ und $s \in S$.

$$s \text{ heißt Median} :\Leftrightarrow rg(s) = \left\lceil \frac{n+1}{2} \right\rceil.$$

2.2.1 Das Problem

Gegeben Sei S , $|S| = n$ paarweise verschiedene Zahlen.
Nun wollen wir den Median s von S möglichst effizient finden.

2.2.2 Algorithmus I in $\Theta(n \cdot \log n)$

Was die Laufzeit schon nahe legt, bedienen wir uns hier eines Sortieralgorithmuses.

1. Sortiere S . z. B. mit Heap - Sort .
Benötigt $\Theta(n \cdot \log n)$ Schritte.
2. Gib das Element an der Stelle $\lceil \frac{n+1}{2} \rceil$ aus.
Benötigt $\Theta(1)$ Schritte.

Laufzeit: $T(n) = \Theta(n \cdot \log n) + \Theta(1) = \Theta(n \cdot \log n)$.

Da für (vergleichsbasiertes) Sortieren jede Lösung mit $\Omega(n \cdot \log n)$ beschränkt ist, kann eine Lösung für das Medianproblem die Sortierung verwendet nicht schneller sein. Bleibt zu untersuchen, ob der Median ähnlich schwer ist, oder ob es einen Algorithmus gibt, der das Problem schneller lösen kann.

2.2.3 SELECT in $O(n)$

Angenommen es existiert eine Funktion SPLITTER(S), welche uns ein Element $q \in S$ liefert, so dass gilt:

$$rg(q) \geq \left\lfloor \frac{1}{4} n \right\rfloor \quad \wedge \quad rg(q) \leq \left\lceil \frac{3}{4} n \right\rceil.$$

Lemma: Angenommen wir können SPLITTER ohne weitere Kosten benutzen. Dann können wir den Median in $O(n)$ Zeit berechnen.

Beweis: Um diese Aussage zu beweisen lösen wir das allgemeinere Problem

$$\text{SELECT}(k, S)$$

finde Element mit Rang k . Dieses Problem wird "Auswahlproblem" genannt.

Idee: Nehme SPLITTER als PIVOT Element und teile die Menge der Daten daran auf.

Pseudocode:

```

SELECT( k , S )
  IF |S| < 100 THEN
    RETURN BRUTFORCE( k , S )  // z. B. Algorithmus I
  q ← SPLITTER( S )
  S< ← { s ∈ S | s < q }
  S> ← { s ∈ S | s > q }
  IF |S<| ≥ k THEN
    RETURN SELECT( k , S< )
  ELSE IF |S<| = k - 1 THEN
    RETURN q
  ELSE
    RETURN SELECT( k - |S<| - 1 , S> )

```

Laufzeitanalyse:

Da $rg(q) \in [\lfloor \frac{1}{4} n \rfloor, \lceil \frac{3}{4} n \rceil]$ gilt $|S_{<}|, |S_{>}| \leq \frac{3}{4} n$.

Also gilt:

$$T(n) \leq \begin{cases} O(1) & , n < 100 \\ O(n) + T(\frac{3}{4} n) & , \text{sonst} \end{cases}$$

Behauptung:

$$T(n) \in O(n)$$

Beweis:

$$\begin{aligned}
T(n) &\leq c \cdot n + T\left(\frac{3}{4} n\right) \\
&\leq c \cdot n + c \left(\frac{3}{4} n\right) + T\left(\left(\frac{3}{4}\right)^2 n\right) \\
&\leq c \cdot n \sum_{i=0}^{\infty} \left(\frac{3}{4}\right)^i + O(1) \\
&\leq (4c) \cdot n + O(1) \\
&= O(n)
\end{aligned}$$

□

2.2.4 Implementierung von SPLITTER

Damit k-SELECT die versprochene lineare Laufzeit erreicht, müssen wir uns als nächstes die Implementierung von Splitter ansehen. Da wir uns in jedem Schritt einen neuen Splitter besorgen, muss die Laufzeit sehr gering gehalten werden.

Randomisierte Lösung

Die erste Idee ist es, statt dem SPLITTER mit den gewünschten Eigenschaften einfach einen zufällig Gewählten zu nehmen. Wenn man diese Laufzeit berechnen wird man auch auf eine lineare kommen.

Um dieses Problem zu lösen werden wir später Randomisierte Algorithmen betrachten und wie man Laufzeiten aus Erwartungswerten bestimmt.

BFRPT - Algorithm

Der Algorithmus wurde nach seinen Entdeckern Blum¹, Floyd², Pratt, Rivest³, Tarjan⁴ benannt.

Grundlegend funktioniert der Algorithmus folgender Maßen:

Man wählt zufällig eine Stichprobe $S' \subseteq S$ mit $|S'| = \lfloor \frac{n}{5} \rfloor$, so dass der Median von S' ein guter Splitter von S ist. Bestimme rekursiv den Media von S' .

Wählen von S'

Die Idee ist S in 5er Gruppen zu unterteilen. Innerhalb dieser Gruppen können wir den Median in konstanter Zeit findet. Baue aus den Medianen der 5er Gruppen die Menge S' und nimm deren Median.

Lemma: Der Median von S' ist ein guter SPLITTER von S , wenn n groß genug ist.

Anschaung: HIER WIRD NOCH EIN BILD UND ERKLÄRUNG EINGEFÜGT!!

Beweis:

Wir wollen prüfen, ob der Median, den wir finden, wirklich SPLITTER Eigenschaften besitzt. Das heißt wir wollen wissen, ob min. $\frac{1}{4}$ kleiner und $\frac{1}{4}$ größer ist.

Größer:

Es sind $\lceil \frac{1}{2} \lceil \frac{n}{5} \rceil \rceil$ Elemente aus S' größer als der Median. Da alle Elemente aus S' Mediane ihrer 5er Gruppen sind, wissen wir, das in jeder dieser Gruppen 3 Elemente größer sind als unser gefundener Median. Dies gilt für alle Gruppen, außer die Gruppe vom Median selber und die mögliche letzte Gruppe.

Dies führt zu $3 \cdot \lceil \frac{1}{2} \lceil \frac{n}{5} \rceil \rceil - 3$

¹Turing Award 1995

²Turing Award 1978

³Turing Award 2002

⁴Turing Award 1986