

Max Wisniewski , Alexander Steen

Tutor: Lena Schlipf

Aufgabe 1

Sei $S = \{s_1, s_2, \dots, s_n\}$ eine Menge von n paarweise verschiedenen Elementen aus einem totalgeordneten Universum. Seien w_1, w_2, \dots, w_n positive Gewichte, so dass das Element s_i Gewicht w_i hat. Es gelte $\sum_{i=1}^n w_i = 1$. Gesucht ist der *gewichtete Median* von S .

- (a) Angenommen, Sie haben eine Funktion, welche den gewichteten Median in Zeit $T(n)$ bestimmt. Zeigen Sie, wie man den (normalen) Median in Zeit $O(n) + T(n)$ berechnen kann.

Beweis: Als Eingabe für unseren Algorithmus (Median) bekommen wir eine Liste von Werten (s_1, \dots, s_n) . Diese erweitern wir nun auf die Form für den gewichteten Median. Dazu legen wir eine 2. Liste mit den Werten an (oder erweitern die andere Liste auf Tupel (s_i, w_i) , was beides auf das selbe hinaus läuft). Für die Gewichte wählen wir $\forall 1 \leq i \leq n : w_i = \frac{1}{n}$. Auf die neue Struktur können wir den Algorithmus für den *gewichteten Median* anwenden.

Laufzeit: Wir konstruieren zunächst die neue Liste. Dafür gehen wir einmal drüber und erzeugen Tupel. Das Gewicht können wir in $O(1)$ erstellen und den Tupel auch. Dies tun wir für n Elemente. Je nachdem, ob wir n besitzen oder noch suchen müssen, haben wir als Laufzeit n oder $2n$. Wir benötigen aber für das Erstellen der neuen Eingabe $O(n)$ Schritte. Danach führen wir den gegebenen Algorithmus aus.
 $\Rightarrow T_{\text{Median}}(n) = T_{\text{gewichteter Median}}(n) + O(n)$

Median: Bleibt zu zeigen, dass das Ergebnis s_g der Median ist:
 Kleinere Elemente, sei n_k die Anzahl der Elemente, die kleiner als s_g sind:

$$\sum_{s_i < s_g} w_i \stackrel{\text{Gewichte}}{=} \sum_{s_i < s_g} \frac{1}{n} \stackrel{\text{Def.: } n_k}{=} \frac{n_k}{n} \stackrel{\text{Def.}}{\leq} \frac{1}{2}$$

$$\Leftrightarrow n_k \leq \frac{n}{2}$$

Kleinere Elemente, sei n_g die Anzahl der Elemente, die größer sind als s_g sind:

$$\sum_{s_i > s_g} w_i \stackrel{\text{Gewichte}}{=} \sum_{s_i > s_g} \frac{1}{n} \stackrel{\text{Def.: } n_g}{=} \frac{n_g}{n} \stackrel{\text{Def.}}{<} \frac{1}{2}$$

$$\Leftrightarrow n_g < \frac{n}{2}$$

Da gelten muss, dass $n_g + n_k + 1 = n$ erfüllen unsere beiden Ergebnisse die Bedingungen für den normalen Median.

- (b) Zeigen Sie, wie man den gewichteten Median in $O(n \cdot \log n)$ Zeit berechnen kann.

Beweis: Wir wählen uns einen geeigneten Sortieralgorithmus. Hier bietet sich Mergesort an. Aus dem letzten Übungszettel wissen wir, dass $T_{\text{Mergesort}}(n) = n \cdot \log n - (n - 1)$ ist.

Nachdem wir unsere Liste sortiert haben tun wir folgendes:

Schritt 1: Erzeuge $sum = 0$ Laufsummenvariable mit 0 und indexvariable $i = 0$

Schritt 2: Rechne $sum \leftarrow sum + w_i$.

Schritt 3: Ist $sum \leq \frac{1}{2}$ inkrementiere i um eins und mache mit Schritt 2 weiter.

Schritt 4: (Ist dies nicht der Fall) Gebe s_i zurück.

Was wir als erstes sehen, ist dass die Summe der Gewichte, die kleiner als der *gewichtete Median* sind, $\leq \frac{1}{2}$ da wir beim ersten mal, wenn es größer ist aus der Schleife gehen und dort nur den Median drauf gerechnet haben. Da wir beim finden über $\frac{1}{2}$ gekommen sind, wissen wir, dass aus der Bedingung, dass die Gesamtgewichte = 1 sind, dass die Gewichte der Elemente, die größer sind $\geq \frac{1}{2}$ sein müssen.

Laufzeit: Die erste Überlegung ist, ob die Schleife abbricht.

Eine einfache Antwort wäre, dass wir alle Gewichte aufsummieren, d.h. wir wissen im n -ten Schritt, dass $sum = 1$ ist. Die Abbruchbedingung wird also spätestens nach n Schritten erfüllt. Da wir aber äußerste Beweisfetischisten sind, werden wir für die Terminierung noch einen formellen Beweis am Ende des Übungsblattes geben. Für die Laufzeit ergibt sich nun: $T(n) = T_{\text{Mergesort}} + n \cdot (c) + d$, wobei c die konstanten Kosten sind, für das aufsummieren der Gewichte und inkrementieren des indexes sind und d die Fixkosten für das anlegen der beiden Variablen sind.

$\Rightarrow T(n) = n \cdot \log n - (n - 1) + n \cdot c + d \in O(n \log n)$.

- (c) Zeigen Sie, wie man den gewichteten Median in $O(n)$ Zeit finden kann, wenn ein Linearzeitalgorithmus zum Finden des normalen Medians zur Verfügung steht.

Aufgabe 2

In der Vorlesung wurden zur Berechnung des BFPRT-Algorithmus die Menge in 5er Gruppen unterteilt.

- (a) Was passiert bei 7er Blöcken.

Splitter: Als erstes prüfen wir, ob die Splittereigenschaft noch erfüllt ist (analog zur Untersuchung aus der VL).

Elemente, die kleiner sind:

Wir haben $n/7$ Gruppen aufgerundet. Davon wissen wir wieder, dass die Hälfte dieser Gruppen einen kleineren Median hat als unser gefundener Splitter. In jeder dieser Gruppen sind 4 Elemente kleiner als der jeweilige Median (und durch Transitivität kleiner als der Splitter). Dies gilt für alle Gruppen, bis auf die nicht voll besetzte (da können 3 Fehlen) und die Gruppe des Splitters (in der der Splitter fehlt)

$\Rightarrow n_k = 4 \cdot \left\lceil \frac{1}{2} \cdot \left\lceil \frac{n}{7} \right\rceil \right\rceil - 4$ Elemente, die größer sind:

Wir haben hier exakt die selbe Abschätzung, wie oben. $n/7$ Gruppen, von denen die Hälfte größer ist, diese besitzen jeweils 4 Elemente, von denen wir die

Größe relativ zum Splitter kennen. Davon gehen wieder 4 Elemente ab. Aus der letzten Gruppe und der Splitter selber.

$$\Rightarrow n_g = 4 \cdot \left\lceil \frac{1}{2} \cdot \left\lceil \frac{n}{7} \right\rceil \right\rceil - 4$$

Nun können wir untersuchen, wie viele Elemente wir wegschmeißen können:

Wir schätzen das ganze erstmal nach unten ab:

$$\begin{aligned} 4 \cdot \left\lceil \frac{1}{2} \cdot \left\lceil \frac{n}{7} \right\rceil \right\rceil - 4 &\geq 4 \cdot \frac{1}{2} \cdot \frac{n}{7} - 4 && \geq \frac{1}{4} \\ \Leftrightarrow &&& \frac{2}{7} \cdot n &\geq \frac{17}{4} \\ \Leftrightarrow &&& n &\geq \frac{17 \cdot 7}{4 \cdot 2} \\ \Rightarrow &&& n &\geq 15 \end{aligned}$$

Beweis: Nun bestimmen wir noch die Laufzeit. Als erstes gilt $\Omega(n)$ als Komplexität des Problems (nicht des Algorithmus). Dies gilt, das wir jedes Element mindestens einmal anfassen müssen, um es zu prüfen. Sollten wir eine echt sublineare Laufzeit erreichen, würden wir einige Elemente nicht betrachten. Wir könnten also einen Fall konstruieren, in dem wir den Median nicht betrachten. Das Ergebnis dieses Algorithmus würde also nicht korrekt sein. $\Rightarrow \Omega(n)$ ist untere Schranke für die Komplexität des Problems.

Für die Beschrenkung nach oben, zeigen wir, dass immer noch gilt $T(n) \in O(n)$

Als Laufzeit können wir ersteinmal, da der Splitter immer noch seine Eigenschaften erfüllt, die Formel aus der VL nehmen:

$$T(n) \leq \begin{cases} O(1) & , n < 50 \\ O(n) + T\left(\left\lceil \frac{n}{7} \right\rceil\right) + T\left(\frac{3}{4}n\right) & , \text{sonst} \end{cases}$$

Dies Beweisen wir mit einer Induktion über n.

Behauptung: $\exists \alpha > 0 : T(n) \leq \alpha \cdot n$

I.A. Für $n < 50$

I.S.

$$\begin{aligned} T(n) &\leq O(n) + T\left(\left\lceil \frac{n}{7} \right\rceil\right) + T\left(\frac{3}{4}n\right) \\ &\stackrel{I.V.}{\leq} O(n) + \alpha \left\lceil \frac{n}{7} \right\rceil + \alpha \cdot \frac{3}{4}n \\ &\leq c \cdot n + \alpha \frac{n}{7} + \alpha + \alpha \frac{3}{4}n \leq \alpha n \end{aligned}$$

Zeigen wir nun den letzten Schritt:

$$\begin{aligned} cn + \alpha \cdot \left(\frac{n}{7} + \frac{3}{4}n + 1\right) &\leq \alpha n \\ \Leftrightarrow cn &\leq \alpha \cdot \left(n - \frac{n}{7} - \frac{3}{4}n - 1\right) \\ \Leftrightarrow cn &\leq \alpha \left(\frac{28n - 4n - 21n}{28} - 1\right) \end{aligned}$$

(b) Was passiert bei 3er Blöcken.

Aufgabe 3

(a) Für zwei ganzzahlige Vektoren $x = (x_1; x_2; \dots; x_n)$ und $y = (y_1; y_2; \dots; y_n)$ mit $0 \leq x_i, y_i \leq M$ und einen Wert $u > M$ betrachten wir die Zahlen

$$a = x_1 u^n + x_2 u^{n-1} + \dots + x_n u^1$$

und

$$b = y_1 u^n + y_2 u^{n-1} + \dots + y_n u^1.$$

Zeigen Sie: $a = b \Leftrightarrow x = y$, $a < b \Leftrightarrow x < y$ (lexikographisch).

- (b) Entwerfen Sie einen Algorithmus, der für zwei gegebene Folgen nichtnegativer Zahlen $x = (x_1; \dots; x_m)$ und $y = (y_1; \dots; y_n)$ in "linearer" Zeit entscheidet, ob x als Teilfolge $(y_{i+1}, \dots, y_{i+m})$ in y vorkommt ($0 \leq i \leq n - m$). Berechnen Sie die Kosten des Algorithmus im EKM und im LKM.